


Aula 01

Ciência de Dados



Uni-FACEF

**Departamento de
Computação**



PLANO DE ENSINO

Objetivos

- **Gerais:**

- A **disciplina** tem por **objetivo** fornecer **subsídios** para o aluno aplicar os **conceitos de análise de dados** utilizando a **linguagem de programação Python**



Objetivos

- ***Específicos:***
 - ***Desenvolver habilidades de coleta e pré-processamento de dados***
 - ***Aplicar técnicas de visualização para explorar dados relacionados à diversos repositórios***
 - ***Compreender os conceitos fundamentais de estatística descritiva e inferência estatística aplicada ao mercado/indústria***
 - ***Utilizar Python e bibliotecas específicas para análise de dados***

Plano de Ensino

- ***Ementa:***

- ***Introdução à análise de dados; Coleta e pré-processamento de dados; Exploração e visualização de dados; Estatística descritiva; Inferência estatística; Modelagem estatística com Python; Ferramentas e bibliotecas para análise de dados***



Plano de Ensino

- ***Metodologia:***
 - ***Aulas Teóricas***
 - ***Laboratório de Informática (Prática)***
 - ***Recursos audiovisuais (Datashow)***



Plano de Ensino

- ***Critérios de Avaliação:***
 - ***NP1 (9 pontos) + Exercícios (1 pontos)***
 - ***NP2 (9 pontos) + Exercícios (1 pontos)***
 - ***Aprovação: MF $\geq$ 6,0 (cinco)***
 - ***Frequência Mínima: 75%***



Conteúdo Programático

- 1. Introdução à Análise de Dados***
- 2. Coleta e Pré-processamento de Dados***
- 3. Exploração e Visualização de Dados***
- 4. Estatística Descritiva***
- 5. Inferência Estatística***
- 6. Ferramentas e Bibliotecas Python para Análise de Dados***

Plano de Ensino

- ***Bibliografia***

- ***Básica***

- DUNTEMAN, G. H. *Introduction to Statistics for the Social Sciences*. Wiley, 2015.
 - VANDERPLAS, J. *Python Data Science Handbook*. O'Reilly Media, 2016.
 - BROWNLEE, J. *Machine Learning Mastery with Python*. Machine Learning Mastery, 2020.



- ***Bibliografia***

- ***Complementar***

- WICKHAM, H. *ggplot2: Elegant Graphics for Data Analysis*. Springer, 2016.
 - FAWCETT, T. *Data Science for Business*. O'Reilly Media, 2013.
 - HARRIS, C. R. et al. *Array Programming with NumPy*. Nature, 2020.

Exercícios

- ***Entrega***
 - ***Plataforma: AVA***
 - ***CD – Nome do Aluno – Exercício X***





ANÁLISE DE DADOS

Introdução


- *Dados, informação, conhecimento e sabedoria*
 - *Dados, informação e conhecimento são conceitos inter-relacionados que desempenham papéis fundamentais em diversas áreas do conhecimento*
 - *Dados:*
 - *são observações brutas e objetivas, que geralmente são expressos em forma **numérica**, **texto**, **som** ou **imagem***
 - *podem ser coletados de diversas fontes, incluindo **prontuário eletrônico**, **sensores**, **registros administrativos**, **pesquisas** e **questionários***
 - ***não** possuem significado ou valor, mas podem ser organizados, analisados e interpretados para produzir informações*

Introdução

- ***Dados, informação, conhecimento e sabedoria***

- ***Informação:***

- ***resultado do processamento e organização dos dados de maneira a produzir significado e contexto***
- ***conjunto de dados que são analisados, estruturados e contextualizados de forma a tornar-se úteis e compreensíveis***
- ***tem um propósito definido, ou seja, fornece respostas para questões específicas***



Introdução

- ***Dados, informação, conhecimento e sabedoria***

- ***Conhecimento:***

- ***resultado da interpretação da informação e de sua aplicação em determinado contexto, de modo que é gerado um entendimento que permite tomar decisões***
 - ***está diretamente relacionado à capacidade de compreender, relacionar e contextualizar informações em uma perspectiva mais ampla, possibilitando a sua utilização para a resolução de problemas e tomada de decisão***



Introdução

- *Dados, informação, conhecimento e sabedoria*

- *Sabedoria:*

- *uso do **conhecimento** e da **compreensão** para tomada de decisão por meio de escolhas **éticas** e **sábias**, considerando as implicações de longo prazo e o impacto em outras pessoas e no mundo*



Introdução

- ***Dados, informação, conhecimento e sabedoria***




Figura 1 - Pirâmide DIKW, adaptado de Shortliffe et al. 2006

Introdução

- ***Dados, informação, conhecimento e sabedoria***



Figura 1 - Pirâmide DIKW, adaptado de Shortliffe et al. 2006

- **Qualidade dos Dados**

- *É importante contar com SI **robustos** e **eficientes**, que sejam capazes de lidar com **grandes volumes** de **dados**, integrar diferentes fontes de informação e garantir a **qualidade** e **veracidade** dos dados*
- *É imprescindível investir em **treinamento** e **capacitação**, para garantir que os **dados** sejam **registrados** de **forma precisa** e **completa**, e que sejam utilizados de **forma apropriada** para a **tomada de decisão***

- ***Qualidade dos Dados***

- *Se os dados utilizados em análises **não** tiverem qualidade, quer durante os processos convencionais quanto na pesquisa científica, pode haver **graves consequências** no que tange a tomada de decisão*
- *Dados de **baixa qualidade** podem levar a **erros** na tomada de decisão, que podem afetar a segurança e eficácia dos processos empresariais*

- **Qualidade dos Dados**

- *É fundamental que os dados coletados e registrados sejam **precisos**, **atualizados** e **confiáveis***
- *O processo de **validação** e **verificação** dos dados também são etapas importantes para garantir sua **qualidade** e **confiabilidade**, além de ser importante **investigar as causas dos erros**, como **corrigi-los** e definir **processos para evitá-los no futuro***



Introdução

- ***Qualidade dos Dados***
 - ***Desafios dos 4Vs***




Figura 2 - Desafios dos 4Vs da coleta e análise de dados. Fonte: adaptado de Peek, 2013

Introdução

- **Qualidade dos Dados**
 - **Desafios dos 4Vs**




Figura 2 - Desafios dos 4Vs da coleta e análise de dados. Fonte: adaptado de Peek, 2013

Introdução

- **Qualidade dos Dados**
 - **Desafios dos 4Vs**




Figura 2 - Desafios dos 4Vs da coleta e análise de dados. Fonte: adaptado de Peek, 2013

Introdução

- **Qualidade dos Dados**
 - **Desafios dos 4Vs**





Figura 2 - Desafios dos 4Vs da coleta e análise de dados. Fonte: adaptado de Peek, 2013

Introdução

- **Qualidade dos Dados**
 - **Desafios dos 4Vs**



- **Qualidade dos Dados**

- **Desafios dos 4Vs**

- **Volume:**

- *grande volume de dados gerados pode **difícultar** a coleta, armazenamento, processamento e análise dos dados*
 - *é necessário ter **sistemas capazes de lidar com grandes volumes de dados para garantir que as informações sejam registradas de forma completa e precisa***



Introdução

- **Qualidade dos Dados**

- **Desafios dos 4Vs**

- **Velocidade:**

- a **velocidade** com que os **dados** são **gerados** também é um **desafio**
 - em alguns casos, como em **monitoramento de pacientes em tempo real**, é necessário que os **dados** sejam **registrados** e **processados** imediatamente para **garantir** um **atendimento eficiente**



- ***Qualidade dos Dados***

- ***Desafios dos 4Vs***

- ***Variedade:***

- a ***variedade*** de fontes de dados, como ***informações clínicas, imagens, dados de sensores e informações de redes sociais***, também pode ***dificultar a coleta e análise dos dados***
 - ***é importante ter sistemas que sejam capazes de lidar com diferentes tipos de dados e integrá-los de forma apropriada***

- ***Qualidade dos Dados***

- ***Desafios dos 4Vs***

- ***Veracidade:***

- *a veracidade dos dados é fundamental para garantir a sua **qualidade** e **confiabilidade***
 - *a coleta de dados deve ser feita de forma precisa e confiável, evitando **erros** e garantindo a validade dos dados*

Introdução

- **Qualidade dos Dados**

- **Desafios dos 4Vs**

- **Veracidade:**

- a **veracidade** dos dados é fundamental para garantir a sua **qualidade** e **confiabilidade**
 - a **coleta** de dados deve ser feita de forma **precisa** e **confiável**, evitando **erros** e garantindo a **validade** dos dados

A **qualidade** dos dados é um **fator crítico** para a **tomada** de decisão, e é importante garantir que os **dados** coletados e registrados nos **SIs** sejam **precisos**, **atualizados** e **confiáveis**, para proporcionar uma **tomada de decisão** mais assertiva.

- ***Qualidade dos Dados***




Figura 3 - Dimensões de qualidade de dados

- **Qualidade dos Dados**

- **Dimensões de Qualidade de Dados**

- **Relevância:**

- se refere à **importância** e **utilidade** dos **dados** para o **problema** ou **questão** que está sendo **investigado**, **dados** que **fornece** **informações significativas** e **úteis** para a **tomada de decisões**

- **Consistência:**

- se refere à **uniformidade** dos **dados** e à **ausência** de **contradições** ou **inconsistências** entre eles

- ***Qualidade dos Dados***

- ***Dimensões de Qualidade de Dados***

- ***Reprodutibilidade:***

- se refere à **capacidade** de **replicar** ou **reproduzir** os **resultados e análises a partir dos mesmos dados**

- ***Acurácia:***

- se refere à **precisão** e **confiabilidade** dos **dados**, ou seja, **quão bem eles representam a realidade ou o fenômeno estudado**

- ***Qualidade dos Dados***

- ***Dimensões de Qualidade de Dados***

- ***Compleitude:***

- se refere ao **grau** em que **todos** os **dados relevantes** para a **análise** estão disponíveis e foram coletados

- ***Disponibilidade:***

- se refere à **facilidade** de **acesso** aos **dados**, **garantindo** que sejam **acessíveis** e **utilizáveis** por outros **profissionais** e **pesquisadores**, quando necessário e com **autorização ética** para **fazê-lo**

- ***Coleta de Dados***

- ***Definir o objetivo da coleta de dados***

- ***Antes de começar a construir o instrumento, é importante definir claramente o objetivo da coleta de dados***

- ***Exemplo:***

- ***o objetivo pode ser avaliar a eficácia de um tratamento ou compreender melhor um grupo populacional específico***



Introdução

- *Coleta de Dados*

- *Selecionar a população-alvo*

- *Definir a população-alvo para a coleta de dados é fundamental para garantir que as informações coletadas sejam relevantes e úteis para um determinado perfil populacional em questão*



- ***Coleta de Dados***

- ***Selecionar as variáveis a serem coletadas***

- As ***variáveis*** são os ***dados específicos*** que serão ***coletados*** para ***atender ao objetivo da coleta de dados***
 - É ***importante selecionar as variáveis com base em sua relevância e utilidade para a análise dos dados, também é importante especificar a granularidade das variáveis, dando preferência pela coleta do dado primário***
 - Recomendamos a ***criação*** de um ***dicionário*** contendo todas as ***variáveis*** e suas ***especificações de tipos, categorias e limites***

Introdução

- ***Coleta de Dados***

- ***Escolher o método de coleta de dados***

- ***Existem várias formas de coletar dados no contexto empresarial, como **bancos de dados**, **web** e **dados externos**, etc.***
 - ***É importante escolher o método de coleta de dados mais adequado para a população-alvo e as variáveis selecionadas***



- *Coleta de Dados*


- *Desenvolver o instrumento de coleta de dados*

- Após *selecionar* as **variáveis** e o **método** de coleta de dados, é possível *desenvolver* o **instrumento** de coleta de dados
 - O *instrumento* deve ser **claro**, **conciso** e **fácil** de usar para garantir que as *informações coletadas* sejam *precisas e consistentes*

- *Coleta de Dados*

- *Testar o instrumento de coleta de dados*

- *É imprescindível **testar** o **instrumento** de coleta de dados antes de usá-lo para coletar dados em grande escala*
 - *O teste pode **ajudar a identificar problemas e garantir que o instrumento esteja funcionando corretamente***




Introdução

- **Coleta de Dados**

- **Validar o instrumento de coleta de dados**

- É um **processo de avaliação** para **garantir** que o **instrumento** esteja **medindo** o que se **propõe a medir**
 - A **validação** pode **incluir** a **análise estatística** dos **dados coletados** e a **comparação** com **outras fontes de informação** para **garantir** que as **informações coletadas** sejam **precisas** e **confiáveis**



- ***Coleta de Dados***

- ***Considerar os aspectos éticos***

- ***A ética é um aspecto crucial na coleta de dados, pois envolve questões de **privacidade**, **consentimento informado** e **uso adequado** dos dados***
 - ***É importante que os dados sejam coletados com o consentimento informado dos indivíduos, garantindo que eles compreendam o propósito da coleta de dados, como os dados serão utilizados e quem terá acesso a eles***

- *Coleta de Dados*

- *Garantir a segurança dos dados*

- É importante para **proteger** a **privacidade** e **confidencialidade** dos indivíduos, garantindo que suas informações **não** sejam divulgadas sem autorização ou comprometidas por violações de segurança
 - No caso de sistemas computacionais podem ser utilizados diversos procedimentos de segurança, como a **criptografia** de dados, **sistemas** de **autenticação** de usuários e **backups** regulares, entre outros

Referências

NETTO, A. MACIEL, F. Python Para Data Science: e Machine Learning Descomplicado, Alta Books, 2021.

BEHRMAN, K. R. Fundamentos de Python para Ciência de Dados. Bookman, 2022.

GRUS, J. Data Science do Zero - 2º Edição: Noções Fundamentais com Python. Alta Books, 2021.

